

Projet Liora:

Classification de produits e-commerce Rakuten

Groupe du cursus Data Scientist - Promo 2026

Etudiants:

Habiba BOUFI
Ludmilla ARABI
Edern PAMART

Tuteur:

Nicolas MORMICHE

I°) Description du projet

Ce projet vise à cataloguer des produits disponibles sur le site de e-commerce Rakuten selon des données différentes (textes et images). Les données sont issues du challenge « Rakuten France Multimodal Product Data Classification », disponible sur le site challengedata.ens.fr. La possibilité de classer et de répertorier des produits est importante pour les sites de e-commerce, puisque cela permet de réaliser des applications diverses telles que la recommandation de produits et la recherche personnalisée. Dans ce contexte, il s'agit ici de travailler sur le développement d'un modèle de prédiction du code type des produits, en prenant en compte des données textuelles (désignation et description des produits) ainsi que des données images (image du produit).

II°) Contexte d'insertion du projet dans votre métier (technique, économique et scientifique)

Étant chercheur en biotechnologie de formation, le thème initial de classification de produits sur un site de e-commerce comme Rakuten n'a pas de lien direct avec mon domaine d'expertise métier. Cependant, la méthodologie et la problématique sur le plan technique peuvent être facilement reliées à différents aspects de mes activités de recherche. Un exemple type serait ici la prédiction du rôle d'une protéine au sein d'une cellule d'un organisme à l'aide d'un code**, tel que les annotations standardisées Gene Ontology (GO),** incluant par exemple des indices sur la localisation et le rôle de la protéine dans le métabolisme de la cellule (rôle de récepteur, signalisation, structural, etc.). Nous aurions à notre disposition la séquence d'acides aminés de la protéine (données textuelles) couplée à une représentation de sa structure 3D (assimilable aux données images). En effet, la prédiction de données utilisant des images et du texte est de plus en plus courante en biotechnologie, en recherche, comme dans l'exemple cité précédemment, mais également dans des applications plus proches du grand public, notamment dans le domaine de la santé. On peut citer par exemple la prédiction de diagnostic à partir d'une description faite par un patient, associée à de l'imagerie médicale (scanner, radio, etc.). Pour citer un dernier point de convergence sur le plan économique entre ce projet et différentes problématiques rencontrées aujourd'hui dans le domaine des biotechnologies au sens large, la mise en place de ces modèles de prédiction représente un gain de temps considérable à l'échelle d'un projet. Elle permet parfois d'écarter de fausses pistes de recherche et d'optimiser au maximum l'argent et le temps nécessaires à la bonne conduite d'un projet.

III°) Objectifs du projet

L'objectif de ce projet est de concevoir un modèle de machine learning de classification permettant de prédire le code type (prdtypecode) de différents produits en partant d'une description textuelle et d'images relatives à ces derniers présentés sur le site de e-commerce Rakuten. Pour être plus précis on peut ici dire que c'est un modèle de classification multi-classe et car ici la variable cible à prédire peut prendre plus de deux valeurs possible, et multimodale, car nous utilisons à la fois du texte et des images.

IV°) Cadre et organisation des données du projet

Les données en lien avec ce projet sont disponibles sur le site ChallengeData et publiées par le Rakuten Institute of Technology dans le cadre d'un challenge compétitif qui a été remporté en 2020 (lien: https://challengedata.ens.fr/challenges/35). Les mentions légales en lien avec ce projet stipulent que ces données sont confidentielles et appartiennent à l'entreprise Rakuten, et que l'utilisation de ces données doit être limitée à la résolution de la problématique concernant ce projet. Les données disponibles sont divisées en plusieurs fichiers de sorte à favoriser la conception d'un classifieur adapté:

- X_train_update.csv: un fichier au format csv contenant les données textuelles nécessaire à l'entrainement et au test du modèle de classification.
- Y_train_CVw08PX.csv: un fichier au format csv contenant les données textuelles correspondant à la variable cible 'prdtypecode' à prédire (le code correspondant à la catégorie de chaque produit).
- X_test_update.csv: un fichier au format csv contenant les données textuelles servant à fournir les prédictions du futur modèle de classification.
- Un dossier images contenant deux sous dossiers:
  - image_train: contenant les images nécessaire à l'entrainement du modèle combiné avec les informations textuelles disponibles dans le fichier 'X_train_update.csv'
  - image_test: contenant les images nécessaire au prédictions du modèle combiné avec les informations textuelles disponibles dans le fichier 'X_test_update.csv'

Concernant la volumétrie de ces différents jeux de données, nous pouvons faire une première analyse sous forme de tableau pour les fichiers csv:

Table 1°) Représentation synthétique de la volumétrie des données disponibles pour le projet de classification des produits e-commerce Rakuten.

Nom du fichier	Nombres de lignes	Nombre de colonnes/ variables	Liste des variables
X_train_update.csv	84916	4	['designation', 'description', 'productid', 'imageid']
Y_train_CVw08PX.csv	84916	1	['prdtypecode']
X_test_update.csv	13812	4	['designation', 'description', 'productid', 'imageid']

	Sous-dossiers	Nombres de photos	Format
Dossier Images	images/image_train	84916	.jpg
	Images/image_train	13812	.jpg

Ces différents fichiers seront détaillé tout au long de ce rapport lors des différentes analyses et des étapes de Data visualisation demandées.

Nous pouvons déjà présenter un premier affichage des données via le code python disponible en fichier annexe de ce rapport (Data_Viz_PROJET_LIORA.py), notons que

toutes les prochains résultats analyses (représentation graphique, corrélation, tests statistiques, etc.) et les interprétations faites dans ce rapport pour la partie Data Visualisation pourront être retrouvées au sein de ce même fichier.

L'adaptation sous forme de dataframe des données disponibles au sein du fichier 'X_train_update.csv' nouvellement intitulé 'X_train_Rakuten' peut être affiché comme montré ci-dessous:

Figure 1°) Affichage des 10 premières lignes du dataframe 'X_train_Rakuten' contenant les données disponibles dans le fichier 'X_train_update.csv'.

	designation	description	productid	imageid
0	Olivia: Personalisiertes Notizbuch / 150 Seite...	NaN	3804725264	1263597046
1	Journal Des Arts (Le) N° 133 Du 28/09/2001 - L...	NaN	436067568	1008141237
2	Grand Stylet Ergonomique Bleu Gamepad Nintendo...	PILOT STYLE Touch Pen de marque Speedlink est ...	201115110	938777978
3	Peluche Donald - Europe - Disneyland 2000 (Mar...	NaN	50418756	457047496
4	La Guerre Des Tuques	Luc a des idées de grandeur. Il veut or...	278535884	1077757786
5	Afrique Contemporaine N° 212 Hiver 2004 - Doss...	NaN	5862738	393356830
6	Christof E: Bildungsprozessen Auf Der Spur	NaN	91920807	907794536
7	Conquérant Sept Cahier Couverture Polypro 240 ...	CONQUERANT CLASSIQUE Cahier 240 x 320 mm seyès...	344240059	999581347
8	Puzzle Scooby-Doo Avec Poster 2x35 Pieces	NaN	4239126071	1325918866
9	Tente Pliante V3s5-Pro Pvc Blanc - 3 X 4m50 - ...	Tente pliante V3S5 Pro PVC 500 gr/m² - 3 x 4m5...	3793572222	1245644185

De même pour le deuxième fichier, 'X_test_update.csv', nouvellement intitulé 'X_test_Rakuten' peut être affiché comme montré ci-dessous:

Figure 2°) Affichage des 10 premières lignes du dataframe 'X_test_Rakuten' contenant les données disponibles dans le fichier 'X_test_update.csv'.

	designation	description	productid	imageid
84916	Folkmanis Puppets - 2732 - Marionnette Et Théâ...	NaN	516376098	1019294171
84917	Porte Flamme Gaxix - Flamebringer Gaxix - 136/...	NaN	133389013	1274228667
84918	Pompe de filtration Speck Badu 95	NaN	4128438366	1295960357
84919	Robot de piscine électrique	<p>Ce robot de piscine d'un design innovan...	3929899732	1265224052
84920	Hsm Destructeur Securio C16 Coupe Croisi£E: 4 X...	NaN	152993898	940543690
84921	Cadre Universal Pro Mont Accessoires Pour Dji ...	Cadre Universal Pro Mont Accessoires Pour DJI ...	4181949876	1310030687
84922	5 Biberons Roses En Pâte À Sucre	Lot de 5 biberons de 3cm de haut en pâte à suc...	3317712987	1206034470
84923	Maigrir Rester Jeune N°1 Octobre 1974	NaN	3558757378	1222015991
84924	Grand Canapé 3 Places Chesterfield Blanc	Le véritable canapé Chesterfield 3 places<br /...	4167105045	1306015443
84925	Piscine Beach Wave 229x229x56 cm 57495NP	<p>Cette piscine gonflable Beach Wave 57495NP ...	3929890142	1265209967

Et enfin, pour le troisième fichier, 'Y_train_CVw08PX.csv', nouvellement intitulé 'Y_train_CVw08PX' peut être affiché comme montré ci-dessous:

Figure 3°) Affichage des 10 premières lignes du dataframe 'Y_train_CVw08PX' contenant les données disponibles dans le fichier 'Y_train_CVw08PX.csv'.

	prdtypecode
0	10
1	2280
2	50
3	1280
4	2705
5	2280
6	10
7	2522
8	1280
9	2582

Suite à ce premier constat sur les différentes données disponibles et leur volumétrie, nous allons, dans la prochaine partie, effectuer des analyses plus poussées sur la pertinence des variables présentes dans les différents fichiers. L'analyse de la composition des différents jeux de données nous permettra d'établir des hypothèses sur la corrélation et les liens entre différentes variables qui seront vérifier dans un troisième temps grâce à des représentations graphiques commentées avec des tests statistiques.

V°) Analyse des données et de la pertinence des variables

Faisons une première analyse de la pertinence des différentes variables disponibles au sein des différents fichiers décris ci-dessus.

Abordons dans un premier temps l'utilité des variables identifiées précédemment dans les dataframe X_train_Rakuten et X_test_Rakuten ['designation', 'description', 'productid', 'imageid']. Nous poursuivrons par l'analyse de la variable cible contenus dans le dataframe Y_train_CVw08PX: ['prdtypecode'].

A°) Description des variables contenus dans les différents dataframes et sous-dossiers d'images

1°) Dataframes X_test & train_Rakuten

Concernant les variables disponibles dans les dataframes X_train & test_Rakuten, nous avons:

- **La colonne 'designation'**: l'intitulé du produit, qui est une variable explicatives importante du modèle et qui ne comporte pas de valeurs manquantes.
- **La colonne 'description'**: contenant une description textuelle de taille variable des produits qui est également considéré comme une variable explicative mais qui a première vue contient des valeurs manquantes dans les deux dataframes X_test et X_train.
- **La colonne 'productid'**: concerne les identifiants des différents produits (aucune valeurs manquantes dans les différents jeux de données).
- **La colonne 'imageid'**: concerne les identifiants des images associées à chaque produit (aucune valeurs manquantes dans les différents jeux de données).

2°) Dataframe Y_train_CVw08PX

Concernant la variable dans le set Y_train_CVw08PX.csv:

- **La colonne 'prdtypecode'**: contient le code type à prédire (variable cible) à partir des informations disponibles dans notre dataframe X_train_Rakuten. Les données sont segmentées en 27 classes et il n'y a aucune valeurs manquantes.

3°) Sous-dossiers images_train & test

Les images stockées dans les dossiers 'images_test' et 'images_train' du dossier 'images' sont sous format .jpg. Leurs noms permet de lier explicitement un produit avec l'image correspondante grâce aux variables 'productid' & 'imageid'.

Les instructions complémentaires fournies par notre tuteur nous permettent de relier les 27 classes contenues dans la variable « prdtypecode » à une catégorie de produits. Cela nous permettra de mieux interpréter chaque classe et de visualiser le type de produits et d'images attendu pour chacune d'elles lors de la construction du modèle.

Table 2°) Correspondance entre les 27 codes de classe (prdtypecode) et leurs catégories de produits

Catégorie	**Catégorie**
2583	Accessoires de piscine
1560	Ameublement et décoration intérieure
1300	Modélisme
2060	Accessoires et décorations pour la maison
2522	Papeterie
1280	Jouets pour enfants
2403	Séries littéraires
2280	Livres documentaires
1920	Accessoires et décorations textiles
1160	Jeux de cartes à collectionner
1320	Produits pour bébés
10	Littérature étrangère
2705	Littérature historique
1140	Figurines
2582	Accessoires et décorations de jardin
40	Jeux vidéo
2585	Accessoires et outils de jardinage
1302	Accessoires d'extérieur
1281	Jeux pour enfants
50	Accessoires de jeux
2462	Ensembles d'accessoires de jeux ou de jeux vidéo
2905	Jeux vidéo téléchargeables
60	Consoles de jeux vidéo
2220	Accessoires pour animaux de compagnie
1301	Articles pour nouveau-nés et bébés
1940	Alimentation

B°) Analyse des particularités du contenu des différentes variables

Suite à cette première description du contenu des différentes variables, on peut dire que les dataframes X_train et X_test contiennent deux variables explicatives intéressantes qui sont 'désignation' et 'description' qui contiennent des informations cruciales pour la prédiction de 'prdtypecode' qui est ici la variable cible. Les deux autres colonnes contiennent les identifiants reliant l'identité du produit à une image correspondante.

Abordons maintenant les différentes particularités de nos jeux de données, concentrons nous dans un premier temps sur les dataframes X_train_Rakuten et X_test_Rakuten. Dans un second temps, nous nous intéresserons aux données disponible dans le dataframe Y_train_CVw08PX.

1°) Dataframes X_test_Rakuten & X_train_Rakuten

À l'aide de la méthode .info() de la bibliothèque pandas, commençons par obtenir les informations générales relatives à ces deux DataFrames, afin de faire un état des lieux des types de variables présentes et de leur nombre.

Figure 4°) Présentation des informations générales concernant les dataframes X_train & test_Rakuten

```
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   designation  84916 non-null  str
 1   description  55116 non-null  str
 2   productid    84916 non-null  int64
 3   imageid      84916 non-null  int64
dtypes: int64(2), str(2)
```

Infos générales sur X_train_Rakuten

```
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   designation  13812 non-null  str
 1   description  8926 non-null   str
 2   productid    13812 non-null  int64
 3   imageid      13812 non-null  int64
dtypes: int64(2), str(2)
```

Infos générales sur X_test_Rakuten

On constate que les dataframes contiennent deux type de données:

- Les colonnes 'designation' et 'description' sont des chaînes de caractères
- Les colonnes 'productid' et imageid' dont des nombres entiers

Pour mieux comprendre les particularités de ces deux jeux de données, nous allons analyser chaque colonne disponible pour mettre en évidence les différentes particularités des données qu'elles contiennent.

I°) Colonne 'designation'

On constate, en affichant les 40 premières lignes des deux DataFrames, que la langue utilisée pour nommer les produits varie : on retrouve du français, de l'anglais et de l'allemand. Intéressons-nous maintenant aux doublons potentiels au sein de la colonne « designation » pour les deux fichiers disponibles (X_train_update.csv et X_test_update.csv). À l'aide du code présenté dans le fichier Data_Viz_PROJET_LIORA.py, nous identifions 2 651 doublons dans le fichier X_train_update (soit environ 3,1 % des produits) et 131 doublons dans le fichier X_test_update (environ 0,9 %). Cette dernière information, très intéressante, nous amènera à analyser le nombre de doublons dans la colonne 'description' de ces mêmes fichiers, afin de vérifier si les produits dont la désignation est en double ont aussi la même

description. À noter que la colonne ‘designation’ des deux fichiers ne comporte aucune valeur manquante : tous les produits ont une désignation.

II°) Colonne ‘description’

A première vue, cette colonne contient des données textuelles de longueur variables et plusieurs cases semblent ne pas afficher de valeurs, on constate différentes ligne contenant des valeurs ‘NaN’ dans les deux dataframes. On constate en effet que les colonnes ‘description’ des dataset X_train_Rakuten et X_test_Rakuten contiennent respectivement 29800 et 4886 valeurs manquantes ‘NaN’. On a donc 35% de descriptions manquantes dans le fichier X_train_Rakuten et X_test_Rakuten

On constate également des caractères HTLM contenus dans certaines descriptions dans les différents dataset, exemple: ligne 14 du fichier X_train_update, la description contient des caractères comme ‘<br’ ou ‘/>Â’ pouvant rendre complexe l’utilisation de ces descriptions au dans l’entrainement d’un modèle de classification.

Pour finir, et pour faire le lien avec la première colonne, on constate une différence flagrante de longueur entre les différentes chaines de caractères en appliquant la méthode describe() pour chaque colonne ‘designation’ et ‘description’ pour les deux jeux de données X_test et X_train (cf tableau ci-dessous). On compare que les moyennes de longueur des chaînes de caractères dans les colonnes ‘designation’ et ‘description’ sont différentes et que les différences entre les min et max sont également assez éloignés.

Table 3°) Statistiques descriptives de la longueur (en caractères) des colonnes « designation » et « description » des DataFrames X_train et X_test

Statistique	designation (X_train)	description (X_train)	designation (X_test)	description (X_test)
Nombre de valeurs	84 916	55 116	13 812	8 926
Nombres moyen de caractères	70,2	808,2	69,9	813,4
Écart-type	36,8	805,5	36,7	854,6
Minimum	11	1	11	1
1er quartile (25 %)	43	259	43	249
Médiane (50 %)	64	626	64	616
3e quartile (75 %)	90	1 034	90	1 051
Maximum	250	12 451	250	22 299

III°) Colonnes ‘productid’ et ‘imageid’

Ces colonnes sont composées de variables de type int64 comme mentionné ci-dessus, et ne contiennent pas de valeurs manquantes dans les jeux de données X_train et X_test. Comme mentionné au début de ce rapport, les données contenus au sein de ces colonnes permettent d’établir le lien entre les dataframes X_train & X_test et les images stockées dans les sous dossiers du dossier ‘images’.

2°) Dataframe Y_train_CVwO8PX

Continuons maintenant avec l'analyse de notre jeu de données Y_train_CVwO8PX contenant la variable cible 'prdtypecode' qu'on cherche à prédire en utilisant les données stockés dans les dataframes X_train et X_test dans le cadre de la confection de notre modèle de classification.

L'utilisation de la méthode info() nous permet de dire que ce dataframe contient 84916 valeurs entières non-nulles, ce qui veut dire qu'il n'y a aucune valeurs manquantes. Les codes d'identification sont composées d'un numéro de deux à 4 chiffres.

L'utilisation des méthodes nunique(), value_counts() & sort_values() nous permettent de distinguer 27 classes de codes. Chacune de ces classes est composées d'un nombre variable de valeurs comme le montrent le tableau ci-dessous:

Table 4°) Répartition des produits du dataframe Y_train_CVwO8PX selon leur classe (prdtypecode)

prdtypecode	Catégorie	Nb de produits	% du total
2583	Accessoires de piscine	10 209	12,02 %
1560	Ameublement et décoration intérieure	5 073	5,97 %
1300	Modélisme	5 045	5,94 %
2060	Accessoires et décorations pour la maison	4 993	5,88 %
2522	Papeterie	4 989	5,88 %
1280	Jouets pour enfants	4 870	5,74 %
2403	Séries littéraires	4 774	5,62 %
2280	Livres documentaires	4 760	5,61 %
1920	Accessoires et décorations textiles	4 303	5,07 %
1160	Jeux de cartes à collectionner	3 953	4,66 %
1320	Produits pour bébés	3 241	3,82 %
10	Littérature étrangère	3 116	3,67 %
2705	Littérature historique	2 761	3,25 %
1140	Figurines	2 671	3,15 %
2582	Accessoires et décorations de jardin	2 589	3,05 %
40	Jeux vidéo	2 508	2,95 %
2585	Accessoires et outils de jardinage	2 496	2,94 %
1302	Accessoires d'extérieur	2 491	2,93 %
1281	Jeux pour enfants	2 070	2,44 %
50	Accessoires de jeux	1 681	1,98 %
2462	Ensembles d'accessoires de jeux ou de jeux vidéo	1 421	1,67 %
2905	Jeux vidéo téléchargeables	872	1,03 %
60	Consoles de jeux vidéo	832	0,98 %
2220	Accessoires pour animaux de compagnie	824	0,97 %
1301	Articles pour nouveau-nés et bébés	807	0,95 %
1940	Alimentation	803	0,95 %

prdtypecode	Catégorie	Nb de produits	% du total
1180	Figurines à peindre et à assembler	764	0,90 %

On constate une répartition assez hétérogènes des données par classes, en effet la classe avec le plus de valeurs (prdtypecode=2583) en contient 10209 et celle avec le moins de valeurs (prdtypecode=1180) en contient 764 soit un nombre de valeurs environ 12 fois supérieurs entre les classes la plus et la moins fournit.

Cette analyse permet également de justifier le choix de la métrique du projet: l'utilisation du score pondéré-F1 qui nous permettra de quantifier la qualité de prédiction de notre futur modèle. En effet cette métrique est ici utilisé car la répartition entre les classe est fortement déséquilibré ce qui sera une métrique plus fiable à utiliser pour analyser la qualité de prédiction du modèle que l'exactitude.

3°) Fichier 'images' contenant les sous-dossiers 'image_test' & 'image_train'

Ce dossier contient deux sous-dossiers, image_train et image_test, qui contiennent les photos au format .jpg des différents produits associés aux jeux de données respectifs X_train_update et X_test_update. La combinaison des données texte et image repose sur l'utilisation des colonnes « imageid » et « productid » vues précédemment. En effet, le nom du fichier image d'un produit est composé de l'identifiant de l'image puis de l'identifiant du produit, selon le format suivant : image_<imageid>_product_<productid>.jpg

Par exemple : image_1263597046_product_3804725264.jpg.

Cette nomenclature est respectée pour toutes les images des deux sous-dossiers, ce qui rendra fiables et efficaces les étapes d'association entre chaque produit et sa photo, lors de l'entraînement et du test du modèle.

Pour conclure sur cette partie, l'utilisation de méthodes simples disponibles en Python, notamment avec les bibliothèques pandas et matplotlib, nous a permis d'explorer les différents DataFrames mis à disposition et d'identifier les variables explicatives et la variable cible, qui seront clés lors de la construction de notre modèle de classification. Les premières observations et visualisations réalisées sur les différentes variables nous amènent à nous poser plusieurs questions, auxquelles sera consacrée la prochaine partie. Ces questions vont nous permettre de rentrer encore plus en détails dans l'aspect Data Visualisation de nos données afin de mettre en évidence des corrélation à l'aide de représentation graphique et de tests statistiques afin de mettre en lumière la structure, les difficultés et d'éventuels biais du dataset.

Les premières questions qui nous viennent sont les suivantes:

1- Les produits sont ils distribuées de manière uniforme dans toutes les classes présentées ?

2- La présence ou non d'une description d'un produit dépend-elle de sa classe ?

3- La distribution de la longueur des description est elle similaire entre le dataframe X_train et X_test ?

4- La longueur des désignations produits varient elle de manière significatives en fonction des classes ?

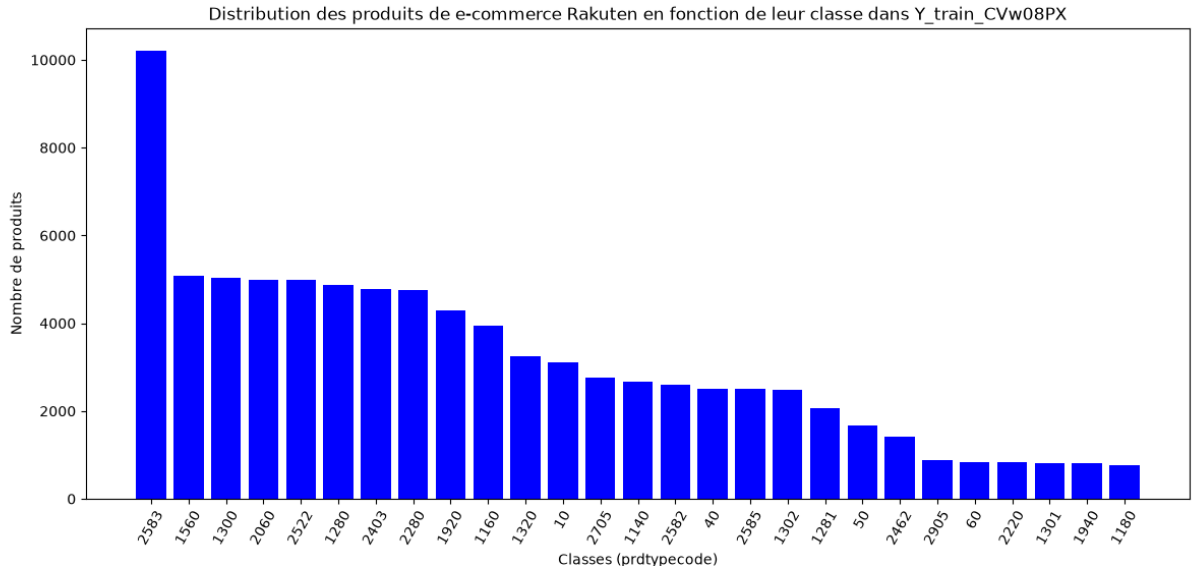
Les images correspondantes au produits de chaque classes sont elles homogènes et remplissent elles toutes de la même manière le format de l'image ?

VI°) Représentations graphiques pertinentes, explications et analyses statistiques

A°) Analyse de la distribution des produits dans les différentes classes

1°) Représentation graphique

Le graphique présenté ci-dessous représente la distribution des produits contenus dans le dataframe X_train_Rakuten en fonction de leur classe. Il a été réalisé en utilisant la bibliothèque 'matplotlib.pyplot', le code est disponible dans le fichier python annexe.



2°) Explications

Nous avons ici organisé nos données disponibles dans les fichiers X_train_update de sorte à visualiser le nombre de produits répertoriés par classes identifiées dans le fichier Y_train_CVw08PX. Sur ce graphique, nous avons représenté le nombre de produits (en ordonnée) par classe (en abscisse) en commençant par la classe contenant le plus de produit, ici la classe 2583 (accessoires de piscine) comptant un peu plus de 10000 produits.

A première vus, la répartition des produits par classe ne semble pas homogène, on remarque que la classe 1180 compte environ 10 fois moins de produits que la classe 2583 (764 contre 10209) . Pour vérifier ce premier constat nous allons réaliser un test statistique du χ2 d'adéquation qui permettra d'étudier la distribution de l'échantillon et de décider si la répartition des produits est uniforme entre les 27 classes.

3°) Tests statistiques

En utilisant le test statistique du $\chi 2$ d'adéquation on peut établir ici que les deux hypothèse H0 et H1 sont:

H0: La répartition des produits entre les 27 classes est uniforme
H1: La répartition des produits dans les 27 classes ne suit pas une répartition uniforme.

Le niveau de signification utilisé pour ce test sera de 0,05 (alpha=0,05), pour rappel si la p-value du test du $\chi 2$ d'adéquation est < 0,05, on rejettera H0 et si p-value => 0,05 nous ne rejetterons pas H0.

Dans notre cas, la p-value de ce test est < 0,001 (cf code python en annexe) donc l'hypothèse H0 est rejetée et nous pouvons conclure que la répartition des produits dans au moins une des classes ne suit pas une répartition uniforme.

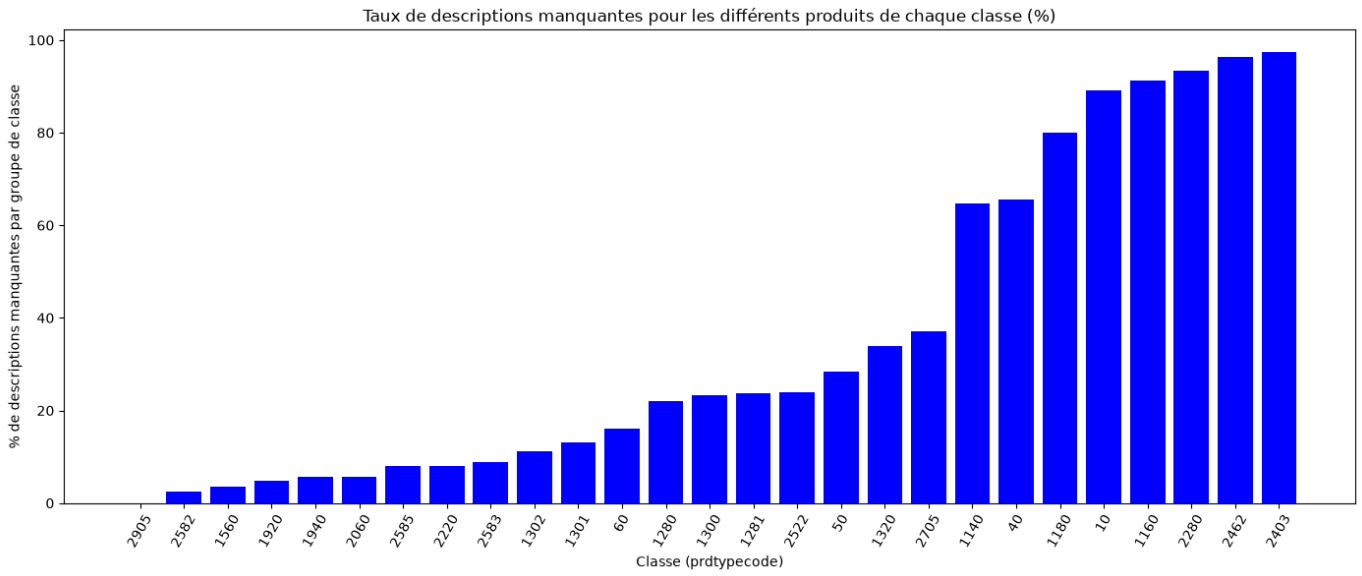
4°) Conclusion

Ce premier résultat nous permet de conclure que la répartition des produits dans les différentes classes n'est pas uniforme. Cette information nous permet de mieux comprendre l'utilisation du F1-score pondérée pour juger de la qualité de prédiction du modèle au vus du déséquilibre de répartition des produits entre les classes.

B°) Taux de descriptions manquantes par classes

1°) Représentation graphique

Suite à nos premières observations sur l'absence de description pour certains produits au sein des fichiers X_train_update et X_test_update, nous avons cherché à savoir si le nombre de description manquantes étaient uniformes au sein des différentes classes. Pour cela nous avons choisi de générer un graphique représentant le pourcentage de description manquantes dans le fichier X_train_update en fonction des 27 classes du fichier Y_train_CVw08PX.
Il a été réalisé en utilisant la bibliothèque 'matplotlib.pyplot', le code est disponible dans le fichier python annexe.



2°) Explications

Le nombre totale de Ce graphique représenté ci-dessus nous montre que la classe avec le moins de descriptions manquantes est la classe 2905 qui ne compte aucune description manquante, contrairement à la classe 2403 qui comptent plus de 90% de descriptions manquantes. Dans ce contexte, notre question est la suivante: la présence ou l'absence d'une description dépend elle de la classe de produits ?

Nous allons répondre à cette question à l'aide d'un test du khi² d'indépendance entre deux variables qualitatives : la variable 'prdtypecode' du jeu de données Y_train_CVw08PX, et une variable binaire appelée 'presence_description' comptabilisant la présence ou l'absence de description dans le fichier X_train_update.

3°) Statistiques

En utilisant le test statistique du $\chi 2$ d'indépendance on peut établir ici que les deux hypothèse H0 et H1 sont:

H0: La présence d'une description est indépendante de la classe du produit
H1: La présence d'une description n'est pas indépendante de la classe du produit

Nous avons dans un premier temps générer la table de contingence à partir d'un data frame reconstituer avec les descriptions des produits dans le data frame X_train_update et les codes produits dans le data frame Y_train_CVw08PX. L'utilisation de cette table de contingence comme paramètre dans la fonction chi2_contingency nous a permis de déterminer que notre p-value pour ce test était inférieur à 0,001 (p-value<0.05), nous permettant de conclure que notre hypothèse H0 était rejeté et qu'il semblerait donc exister une dépendance significative entre la présence de description et la classe du produit.

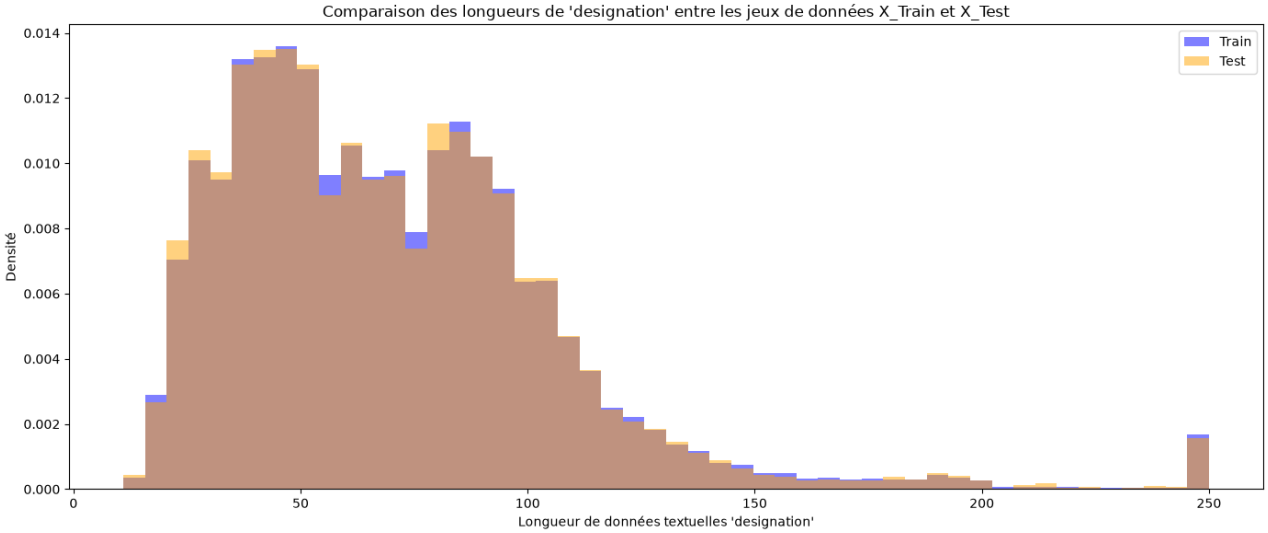
4°) Conclusion

Cette nouvelle observation nous permet de dire qu'il y a une dépendance entre la présence ou l'absence de description et la classe du produit. Dans le contexte du projet et de la création de notre modèle, cela a son importance car la présence ou l'absence de description pourrait être utilisée par le modèle pour identifier la classe d'un produit.

C°) Comparaison de la distribution de la longueur des désignations entre les jeux de données X_train et X_test

1°) Représentation graphique

L'analyse de la distribution de la longueur des désignations entre les données X_train_Rakuten et X_test_Rakuten a son importance car elle permettra de savoir si le modèle entrainé et testé sur les données de X_train sera aussi performant sur les données de X_test. En d'autres termes cela permet de vérifier si le jeu de données de test est représentatif du jeu de données d'entrainement utilisé pour la conception du modèle (pour la distribution des désignations, qui est une des variables explicatives importante du modèle). Le graphique représente ci-dessous a été réalisé en utilisant la bibliothèque matplotlib.pyplot.



2°) Explications

Dans le but de contrôler que la longueur de nos données dans la variable 'designation' de X_train et X_test est distribuée de manière similaire, nous avons représenté deux histogrammes superposés représentant en bleu, la distribution de la longueur des données de la variable 'designation' au sein de X_train et en jaune a distribution de la longueur des données de la variables 'designation' au sein de X_test.

En abscisse nous avons la longueur de chaque 'designation' réparties selon 50 intervalle de longueur et en ordonnée le nombre d'occurence (nombre de fois où une 'designation' d'une certaines longueur apparait dans le jeu de données) mis à l'échelle sous forme de densité pour pouvoir comparer les deux distributions.

A première vue cette distribution semblent très similaires puisque les deux histogrammes mis à l'échelle se superposent de façon quasi-parfaite. Nous allons vérifier à l'aide d'un test statistique si la distribution des données au sein de X_train et X_test est similaire.

Après quelques recherches il semblerait que le test statistique de Kolmogorov-Smirnov permettent de définir si deux échantillons proviennent ou non de la même distribution, c'est donc ce dernier que nous allons utiliser ci-dessous pour déterminer si la distribution des données est similaire ou non.

3°) Test statistique

De la même façon que pour les derniers tests statistiques nous avons dans un premier temps établit les différentes hypothèses H0 et H1:

H0: Les distributions des longueurs de 'designation' entre les jeux de données X_Train et X_Test ne sont pas significativement différentes

H1: Les distributions des longueurs de 'designation' entre les jeux de données X_Train et X_Test sont significativement différentes

Après le calcul de la p-value pour ce test, on constate que p-value=0.61, ce qui est une condition suffisante pour ne pas rejeter H0 et conclure que les distributions de la variable ‘designation’ entre nos deux jeux de données sont similaires.

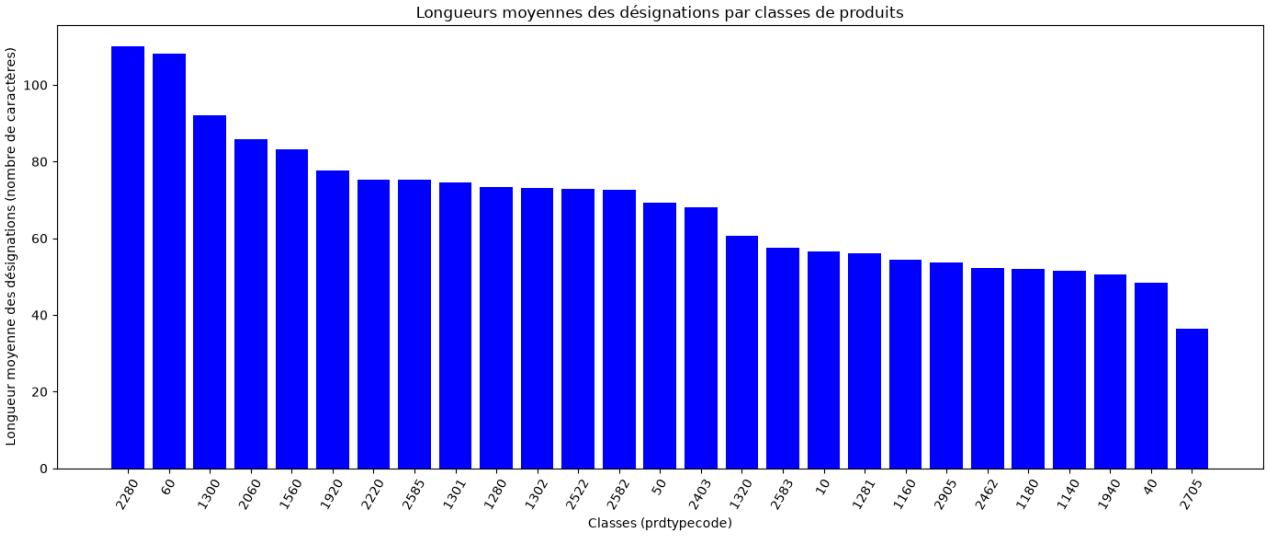
4°) Conclusion

Les résultats de cette analyse sont rassurants car ils indiquent que le jeu de données X_test est représentatif du jeu de données X_train pour la longueur des données textuelles contenues dans la variable ‘désignation’, ont devraient donc s’attendre à ce que les performances du modèle soit conservées au moment du test sur les données de X_test en ayant entrainer le modèle sur X_train.

D°) Longueurs des designations par classe

1°) Représentation graphique

Toujours dans l’optique d’étudier la variable explicative ‘désignation’ dans le dataframe X_train_Rakuten, on cherche maintenant a étudier la longueur moyenne des données textuelles de cette variable en fonction de la classe du produit. La représentation graphique ci-dessous permet de visualiser la longueur moyenne des désignations en fonction de la classe des produits, elle a été réalisé en utilisant la bibliothèque matplotlib.pyplot.



2°) Explications

Nous avons décidé d'analyser la répartition de la longueur moyenne des données de la variable 'designation' du jeu de données X_train en fonction de la classe des produits, contenue dans le jeu Y_train_CVw08PX.

Cette analyse doit nous permettre de déterminer si la longueur des désignations diffère ou non de façon significative selon la classe du produit. On constate dans un premier temps que certaines classes (2280 ou 60 par exemple) présentent une longueur moyenne supérieure à 100 caractères, tandis que d'autres se situent autour de 50 caractères (1140 ou 1940 par exemple).

Il semble donc que certaines classes soient plus disposées à contenir des produits avec des désignations longues. Après différentes recherches, nous avons déterminé qu'un test statistique de Kruskal-Wallis serait adapté dans ce contexte, car il permet de comparer une variable quantitative (la longueur des désignations) entre plus de deux groupes indépendants (les 27 classes), sans supposer la normalité des données ni l'égalité des variances.

3°) Tests statistiques

De la même façon que pour les tests précédents nous avons ans un premier temps établit les différentes hypothèses H0 et H1:

H0: la longueur des désignations se répartit de la même façon dans toutes les classes

H1: la longueur des désignations ne se répartit pas de la même façon dans toutes les classes

Suite à la réalisation de ce test, on constate que la p-value est inférieur à 0.001, signifiant que p-value<0.05 et que donc H0 devait être rejetée. On peut donc dire que la la longueur des désignations ne se répartit pas de la même façon dans toutes les classes.

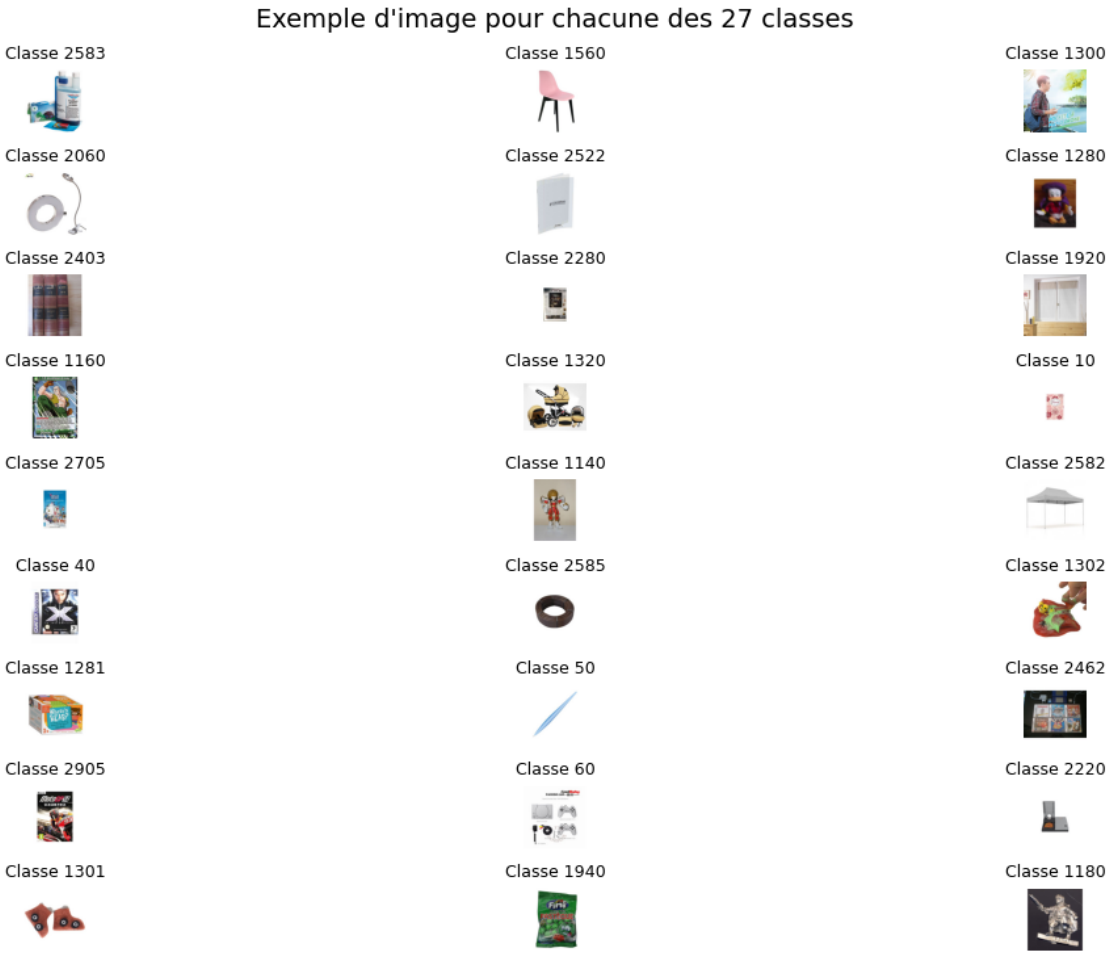
4°) Conclusion

Cette analyse nous permet de dire que la longueur des désignations varie entre les différentes classes de produits, une variable 'longueur_désignations' pour donc être utilisés comme variable explicative lors de la construction du modèle.

E°) Exemples d'images représentatives des 27 différentes classes de produits

1°) Représentation graphique

Pour finir sur ces différentes analyses, nous allons donner un exemple d'images stocker dans le sous dossier image_train pour les différentes classes de produits. Cette analyse visuelle nous permettra de faire un premier constat de la présentation des images et de leur format.



2°) Explications

La dernière représentation concerne les images des produits mises à disposition dans le dossier images, sous-dossier image_train. Nous cherchons ici à identifier les différentes catégories de produits en associant les codes de classe contenus dans le fichier Y_train_CVw08PX aux images du dossier correspondant (images/image_train).

Cette représentation graphique nous permet de mieux comprendre la signification des différents codes de classe, et de savoir à quelles catégories ils correspondent. On retrouve en effet sur les images les catégories associées à chaque code (cf. tableau 2).

Concernant le format des images, on constate qu'elles ont toutes les mêmes dimensions (500 × 500 pixels) et le même mode de couleur (RGB) (cf. code Python en annexe). Cependant, certaines images ne remplissent que partiellement l'espace disponible**. Par exemple,** le produit affiché pour la classe 2705 est difficilement visible,

contrairement à celui de la classe 2582. Cette observation suggère qu'il faudra peut-être recadrer ou zoomer sur les images dont le produit n'occupe qu'une petite partie de l'espace, afin d'améliorer leur lisibilité par le modèle.

3°) Tests Statistiques

Il n'y a pas spécialement de tests statistiques à réaliser dans ce contexte, cette représentation graphique nous as permis de mieux visualiser les différentes catégories de données et de combiner pour la première fois les images du dossier images_train avec les données du fichier X_train_update correspondant.

VII°) Conclusion(s) et perspective(s)

Cette première étape de visualisation des données du projet Rakuten nous a permis de nous familiariser avec les différentes variables disponibles ('designation', 'description', 'prdtypecode', etc.) et de discuter de leur pertinence. L'importance de certaines variables explicatives, comme 'designation' ou 'description', dans les fichiers X_train_Rakuten et X_test_Rakuten, nous a amenés à formuler plusieurs hypothèses sur les liens entre les variables et leur distribution.

Une première exploration a également mis en évidence plusieurs particularités des données textuelles des variables 'designation' et 'description' : des textes multilingues, du bruit (balises HTML) et des doublons.

Par la suite, diverses représentations graphiques, accompagnées de tests statistiques adaptés, nous ont permis d'établir les constats suivants :

- La répartition des produits entre les classes n'est pas uniforme (test du χ^2 d'adéquation) : la plus grande classe compte environ 13 fois plus de produits que la plus petite.
- La présence d'une description dépend de la classe du produit (test du χ^2 d'indépendance). Environ 35 % des descriptions sont manquantes dans les deux fichiers X_train_Rakuten et X_test_Rakuten.
- La longueur des désignations varie selon la classe du produit (test de Kruskal-Wallis), ce qui en fait une variable explicative potentielle.
- Les jeux d'entraînement et de test sont comparables pour la longueur des désignations (test de Kolmogorov-Smirnov, $p = 0{,}61$).
- Les images ont un format homogène (500 × 500 pixels, RGB), mais un cadrage variable, qui nécessitera un prétraitement.